

# Welt der Kinder







# Überblick: Semantische Korpusanalyse mit dem WdK-Explorer

Ben Heuwing

Institut für Informationswissenschaft & Sprachtechnologie

Universität Hildesheim

# **Projektfokus**

Entwicklung digitaler Werkzeuge zur Analyse großer Quellenbestände, die mit hermeneutischen Methoden kaum zu durchdringen sind.

Instrumente sollen der Semantik der Bildungsmedien gerecht werden und 'qualitative' Strukturen aufdecken:

- intertextuelle Verknüpfungen
- thematische Cluster
- semantische Felder

Anwendung auf geschichtswissenschaftliche Fragestellungen



# **Korpus**

#### Historische Schulbücher

- 3803 digitalisierte
   Schulbücher
- Geschichte, Geografie, Realienkunde
- http://gei-digital.gei.de

Insgesamt 799260 Text-Seiten
Umfangreiche Metadaten





DE / EN

Startseite Suchen Stöbern Aktuelles Über das Projekt Partner Nutzungsbedingungen

nporte Sie befinden sich hier: Startseite

#### Letzte Importe

23. Oktober 2015 Geographie für Kinder

Grundriß der Europäischen Staatengeschichte, in Verbindung der Erdbeschreibung und Staatskunde

Hieronymi Freyers Paed. Reg. Hal. Insp. Nähere Einleitung zur Universal-Historie

07. Oktober 2015 M. Georg Christian Raff's, ordentlichen Lehrers der Geschichte und Geographie auf dem Lyceum zu Göttingen, Geographie für Kinder

27. August 2015 Schul-Lesebuch

#### Verfügbare Sammlungen



#### Fibeln vor 1871 (54)

Fibeln oder auch ABC-Bücher waren meist bebilderte, häufig aufwändig illustrierte Erstlesebücher, die als Schulbücher zum Zweck des Erlernens des Lesens eingesetzt wurden.

Die Sammlung umfasst Erstlesebücher aus Deutschland vom 15. / 16. Jahrhundert an bis in das Jahr 1870.



#### Geographieatlanten (119)

Geographieatlanten stellen als didaktisch aufbereitete, systematisch angeordnete und gebundene Sammlungen von Karten eine Sonderform der Atlanten dar und wurden hauptsächlich im Geographieunterricht eingesetzt.

In der vorliegenden digitalen Sammlung finden Sie Geographieatlanten, die in der Zeit zwischen dem 17. Jahrhundert und dem Ende des Kaiserreiches im Jahr 1918 erschienen sind.



#### Geographieschulbücher Kaiserreich (956)

Für den Geographieunterricht wurden Schulbücher verwendet, wie sie in der vorliegenden Sammlung zu finden sind. Der zeitliche Rahmen umfasst die Zeit des Kaiserreiches zwischen 1871 und 1918.



#### Geographieschulbücher vor 1871 (265)

Die Schulbücher dieser digitalen Sammlung wurden in der Zeit vom 17. Jahrhundert bis in das Jahr 1870 für den Geographieunterricht verwendet.

DEUTSCHLAND

Geschichtsatlanten (53)

#### Welt der Kinder Explorer - Beta VdK 07 03

napoleon Suchen

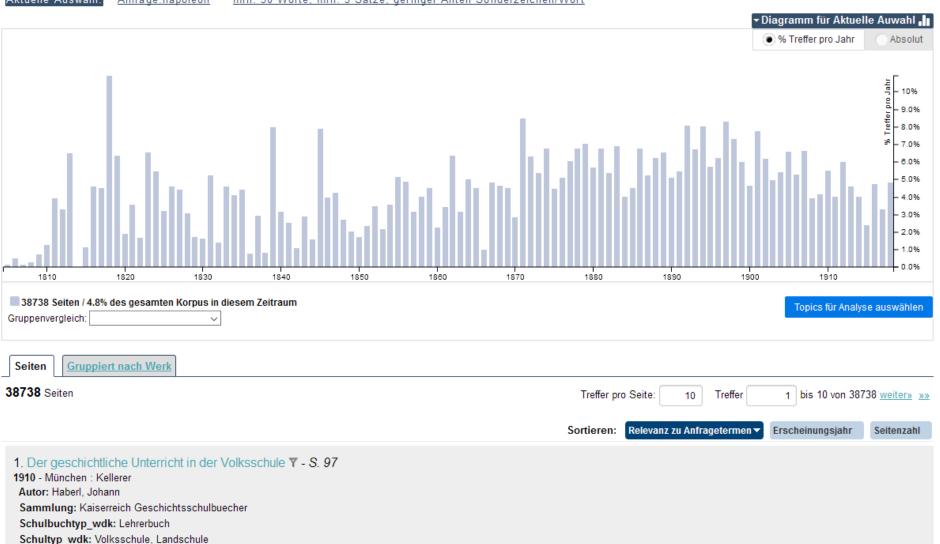
Aktuelle Auswahl:

Anfrage:napoleon

Schultyp Allg wdk: Niedere Lehranstalten

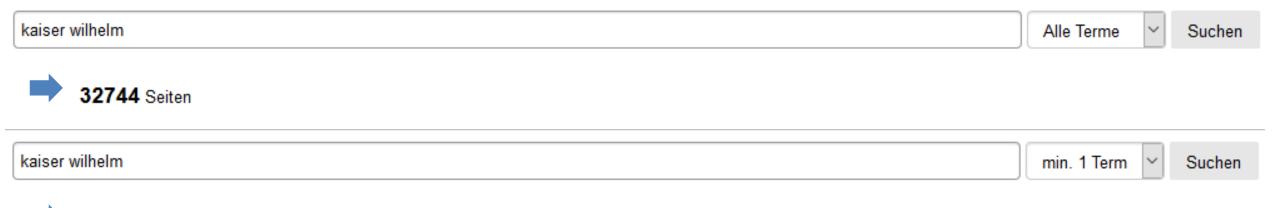
min. 50 Worte, min. 3 Sätze, geringer Anteil Sonderzeichen/Wort





# Suchanfragen

191578 Seiten



# Kombination der Anfrageterme:

Trefferdokumente müssen Alle Terme enthalten (Standardeinstellung - Verknüpfung mit UND)

Trefferdokumente müssen mindestens einen der Terme enthalten (Verknüpfung mit ODER)

### **Einfaches Stemming wird auf die Suchanfrage angewendet**

Regierungen → regierung (findet regierungen und regierung)

regierte → regiert (findet Seiten mit regierte und regiert, aber nicht regieren)

*Kaiser* → *kais* (findet *Kaiser*, aber nicht *Kaiserin*)

# **Anfrage-Syntax: Erweiterte Möglichkeiten**

kaiser	Alle Seiten mit <i>kaiser</i> oder einer Flektion (über einfaches Stemming zu kais) im Text. Groß-Kleinschreibung spielt keine Rolle								
kai*	Alle Seiten mit kaiser oder kai (z.B. im Hamburger Hafen) und mit längeren Termen								
kaiser AND könig	Alle Seiten sowohl mit dem Term kaiser als auch könig, entspricht der Anfrage kaiser könig								
Kaiser OR könig	Alle Seiten entweder mit dem Term kaiser oder könig oder mit beiden								
Kaiser -könig	lle Seiten mit dem Term kaiser aber ohne könig								
(Kaiser OR könig) AND Wilhelm	Kombinationen aus AND / OR können mit Klammern kombiniert werden								
"deutschen volkes"	Alle Seiten, auf denen deutsch und volk direkt hintereinander aufterten (Phrasensuche) Achtung: Es werden auch Wort-Flektionen berücksichtigt (stemming): Es wird also nicht nach de exakten Formulierung gesucht!								
"kaisertum Glanzzeit"~2	Alle Seiten, auf denen eine Phrase wie "Kaisertum seine Glanzzeiten" oder "Kaisertums in seiner Glanzzeit" auftritt: Die Begriffe dürfen 2x verändert, d.h. umgestellt oder zusätzliche Begriffe eingefügt werden								
goobi_CatalogIDSource:PP N564100781	Alle Seiten aus dem Werk mit der PPN PPN564100781 (Für Suche nach exaktem Wert)								
goobi_TitleDocMain:Hilfsbu ch	Alle Seiten aus Werken, die Hilfsbuch im Titel haben (für indexierte Felder text, text_normalized)								

https://cwiki.apache.org/confluence/display/solr/The+Extended+DisMax+Query+Parser

# Alle aktiven Anfrageterme und Filter

werden unterhalb der Anfrage angezeigt



# Vorhandene Metadaten und darauf basierende Filter

Anzahl Seiten

Bibliographische Angaben zu jedem Werk: Titel, Erscheinungsort, Verlag, Herausgeber

Metadaten aus OCR-Prozess, aus Bibliothek des GEI und aus dem Projekt WdK

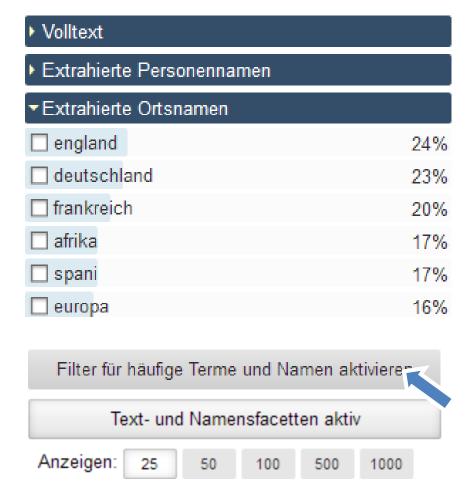
#### **Beispiele:**

- Verlag / Verlag (gesäubert WdK): Ursprünglicher Wert und einmal Schreibweisen normalisiert
- Erscheinungsort / Ort\_erste\_Angabe: Reduziert auf erste Ortsnennung
- Schulform\_opac: Extrahiert aus Opac-Verschlagwortung
- Erscheinungsjahr: Jahrzehnt oder beliebige Zeitspanne
- Inhalt Raum/Thema: Forschungsbezug WdK

#### → Cheat-Sheet mit Filternamen



# **Spezielle Filter**



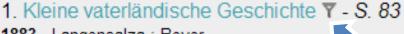
# Häufige Namen und Terme:

Rechenintensiv, müssen zunächst aktiviert werden.



#### Junkfilter:

Standardmäßig aktiviert, Seiten mit sehr wenig korrekt erkanntem Text herausfiltern



1883 - Langensalza : Beyer

Autor: Wolf, Carl

Hrsg.: , Auflage: 2

Sammlung: Kaiserreich Geschichtsschulbuecher

Schulbuchtyp\_wdk: Schülerbuch

## Filter auf Ergebnisse aus einzelnen Werk

# Analyse im Zeitverlauf - Analysemöglichkeiten

Seitenzahl im Zeitverlauf



Im Gruppenvergleich oder Vergleich mit vorheriger Anfrage

Gruppenvergleich Vergleich mit vorheriger Anfrage

### Topic Intensität für ausgewählte Topics anzeigen

Oder ein einzelnes Topic im Vergleich

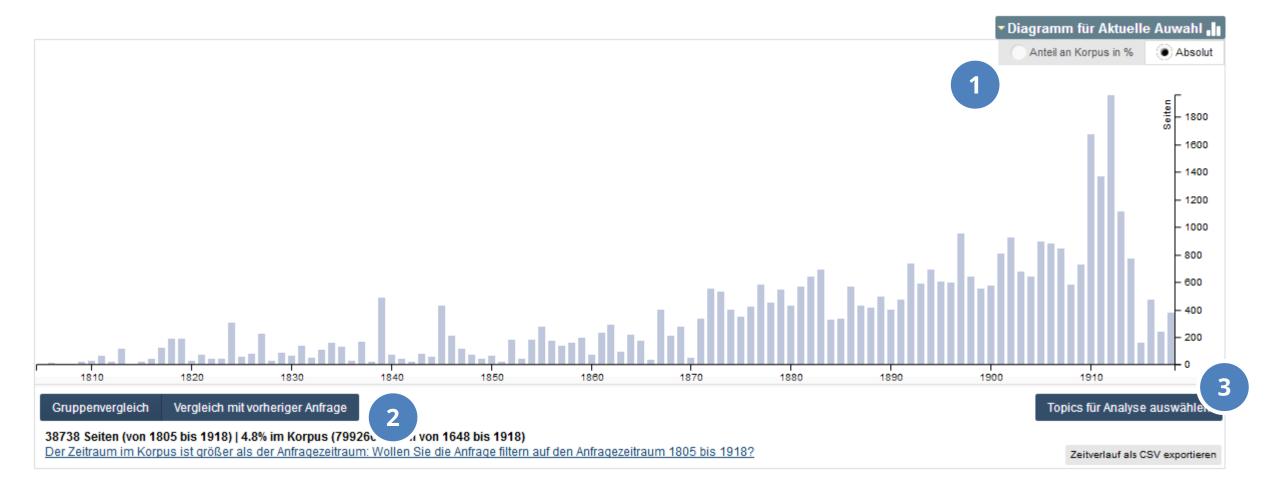
#### Optionen

Gleitender Durschnitt über 5 Jahre, um Trends zu erkennen

Wenn Anfrage oder Filter aktiv: Normalisiert an Seitenzahl im jeweiligen Jahr um Vergleiche zwischen Jahren zu ermöglichen

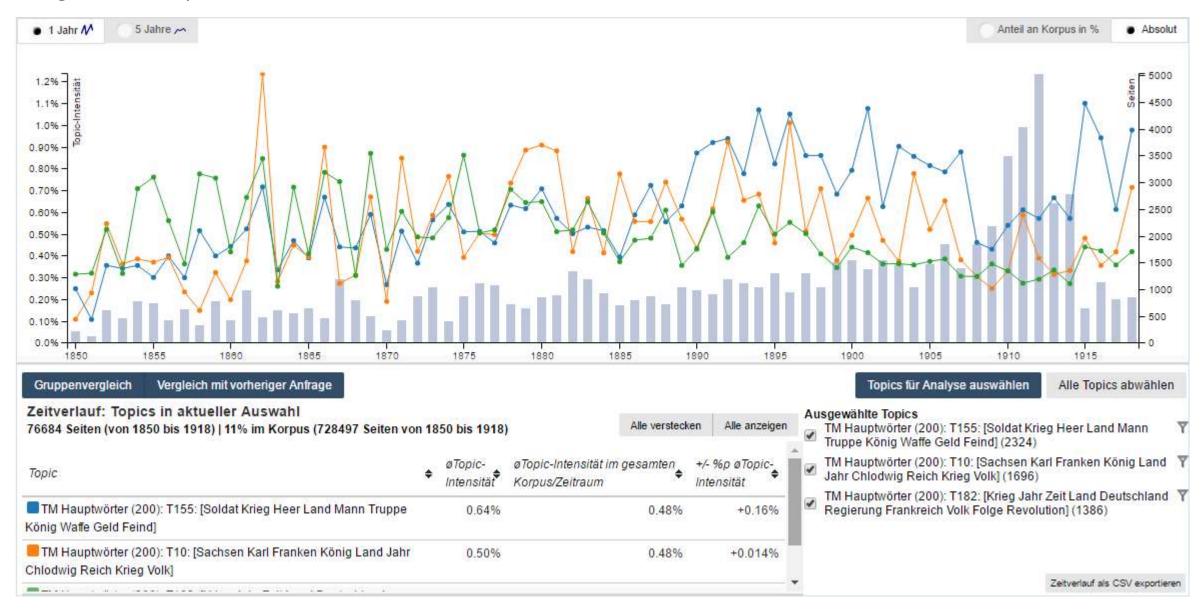


#### Treffer (Seitenzahl) in aktueller Auswahl im Zeitverlauf



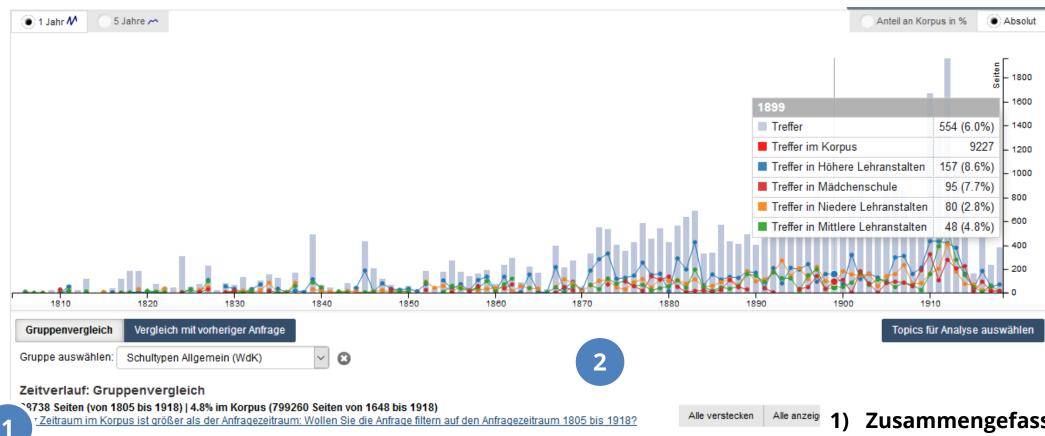
- 1) Absolute Anzahl / Anteil in dem jeweiligen Jahr
- 2) Gruppenvergleich oder Vergleichsanfrage auswählen
- 3) Topics für Analyse auswählen

### Vergleich von Topics im Zeitverlauf



**Beispiel: Kinder (Suchanfrage) und Krieg (Topics)** 

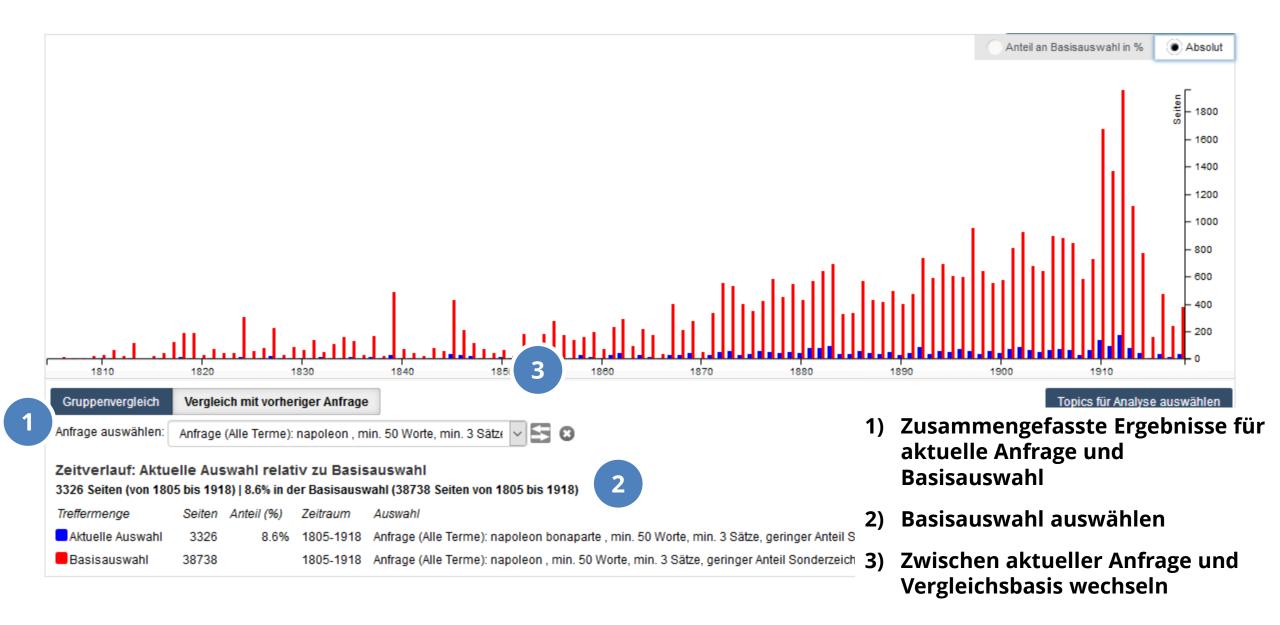
#### Gruppenvergleich im Zeitverlauf



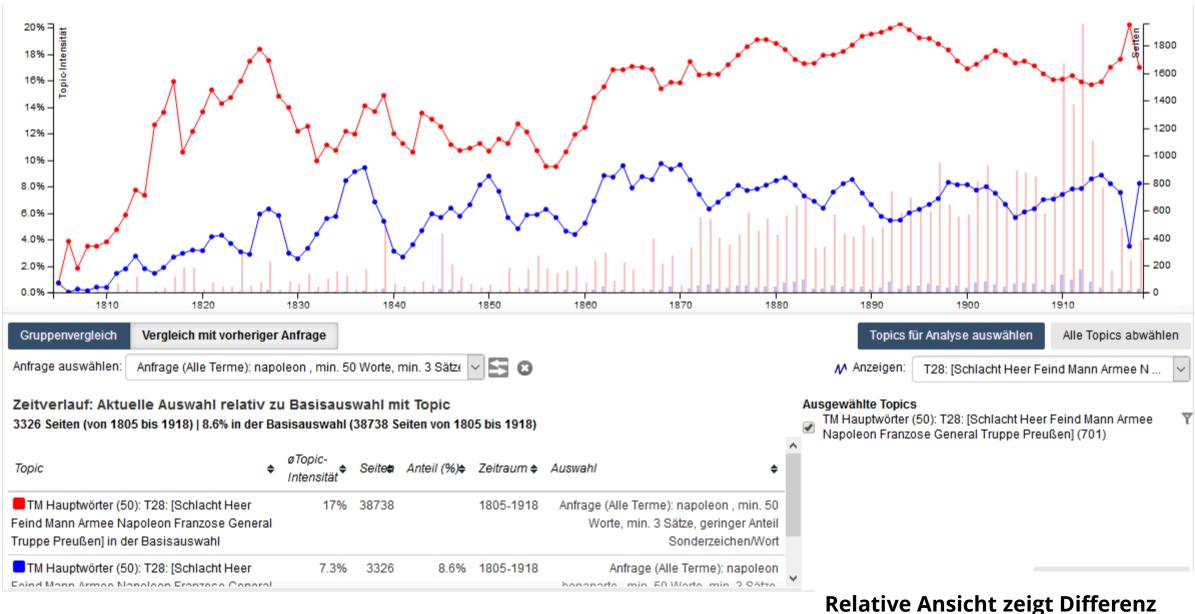
*Jruppe* Treffer/Gruppe +/- %p relativ zu Korpus (4.8%) Höhere Lehranstalten +0.43% 11350 29% 5.3% Niedere Lehranstalten 7093 18% 4.4% -0.50% Mittlere Lehranstalten 6141 16% 4.8% -0.048% Mädchenschule +1.3% 3918 10% 6.1%

- ) Zusammengefasste Ergebnisse für alle Untergruppen:
  - Anteil der Gruppe an aktuellen Treffern und Verglich mit Gruppengröße in Gesamtkorpus
- 2) Hinweis auf unterschiedliche Zeitabschnitte zwischen Anfrage und Korpus durch Auswahl

## Zeitverlauf aktuelle Auswahl im Vergleich zu vorheriger Anfrage als Basisauswahl



#### Topic im Zeitverlauf für aktuelle Auswahl im Vergleich zu vorheriger Anfrage als Basisauswahl



Relative Ansicht zeigt Differenz zwischen Topic in den beiden Mengen

# Vergleichen: Kategorie x Kategorie





Aktuelle	Auswahl:	Anfrage:napoleo	on <u>Erscheinun</u>	gsjahr : [1810 TO 1920]   <u>i</u>	min. 50 Worte, min.	3 Sätze, geringer Anteil Son	derzeich	en/Wort		
/ergleiche:	Schultyp	Allg wdk	gruppiert nach:	Erscheinungsjahr n. Jahrzehnten	Relative Werte	Top-Abweichungen anzeigen:	3 🗸	Berechnen		

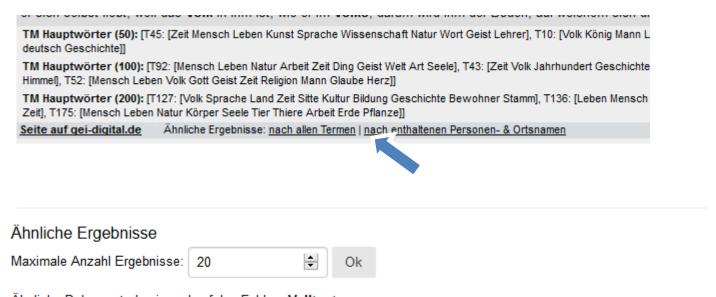
Häufigkeiten für Schultyp\_Allg\_wdk im Vergleich über Erscheinungsjahr n. Jahrzehnten

	Erscheinungsjahr Gesamt		1810 - 1819 1820 - 1829			1830 - 1839 1840 - 1849			1850 - 1859		1860 - 1869		1870 - 18			
# \$	Schultyp_Allg_wdk \$	Anzahl ♦	Anteil \$	Anzahl \$	+/- \$	Anzahl \$ +	/- <b>\$</b>	Anzahl \$ +/-	<b>\$</b>	Anzahl \$ +/-		Anzahl ♦	+/- \$	Anzahl \$	+/- \$	Anzahl
Top-3-Aufsteiger (nur **):						1. [keine Angabe]: +; 2. Bürgerschule: +2		1. [keine Angabe]: +20%		1. [keine Angabe]: +17 2. Realschule: +7% 3. Gymnasium: +7%			talten: +11%	Niedere Lehransta     Höhere Lehransta		1. Höhere
Top-3-Absteiger (nur **):					Höhere Lehranstalten: -20%     Mittlere Lehranstalten: -12%     Niedere Lehranstalten: -10%     Mädchenschule: -5%     Niedere Lehranstalten: -10%			1. Lehrerbildungsanstalten: -8% 2. Mädchenschule: -7% 2. Niedere Lehranstalten: -7% 3. Lehrerbildungsanstalten: -7%				Lehrerbildungsanstalten: -8% 2. Mädchenschule: -4% 3. Alle Lehranstalten: -3%		1. [keine A 2. Lehrerb		
	Seitenzahl pro Erscheinungsjahr:	38690		787	2%	962	2%	1343	3%	1135	2%	1428	3%	1999	5%	
1	Höhere Lehranstalten	11041	28%	71	-20%**	208 -7	7%*	324 -4%		335 +1	%	594	+13%**	678	+5%**	
2	Niedere Lehranstalten	6374	16%	50	-10%**	93 -7	7%**	262 +3%		106 -7	%**	329	+7%**	456	+6%**	
3	Mittlere Lehranstalten	5788	14%	26	-12%**	143 +	0%	201 +0%		111 -59	%**	367	+11%**	352	+3%	
4	Mädchenschule	3761	9%	29	-6%**	43 -5	%**	34 -7%**	±	29 -7	%**	97	-3%*	112	-4%**	
5	Lehrerbildungsanstalten	3259	8%	0	-8%	0 -8	3%	1 -8%**	±	18 -7	%**	0	-8%	17	-8%**	
6	Alle Lehranstalten	1485	3%	0	-4%	30 -1	%	28 -2%		25 -29	%	0	-4%	16	-3%**	
7	Simultanschule	126	0%	0	+0%	0 +	0%	0 +0%		0 +0	%	0	+0%	0	+0%	
8	Gymnasium	116	0%	0	+0%	0 +	0%	0 +0%		80 +7	%**	7	+0%	0	+0%	
9	Realschule	80	0%	0	+0%	0 +	0%	0 +0%		80 +7	%**	0	+0%	0	+0%	
10	Bürgerschule	40	0%	12	+1%**	25 +2	2%**	0 +0%		0 +0	%	0	+0%	0	+0%	
11	Taubstummenschule	40	0%	0	+0%	0 +	0%	0 +0%		0 +0	%	0	+0%	0	+0%	
12	Lehrerseminar	28	0%	0	+0%	0 +	0%	0 +0%		0 +0	%	0	+0%	0	+0%	
13	Einjährigen-Freiwilligen-Prüfung	3	0%	0	+0%	0 +	0%	0 +0%		0 +0	%	0	+0%	0	+0%	
14	Jüdische Lehranstalten	3	0%	0	+0%	0 +	0%	0 +0%		0 +0	%	0	+0%	0	+0%	;

# Ähnliche Ergebnisse zu einzelnen Treffern: More Like This

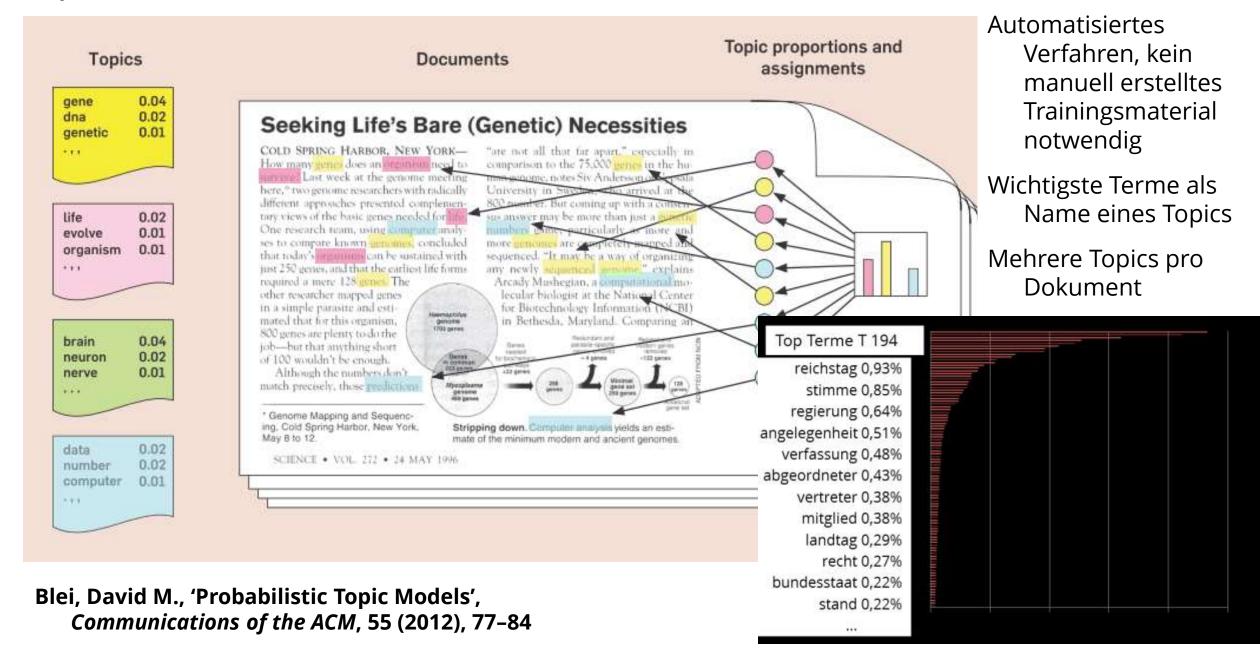
Zu jedem Dokument in WdK-Explore können Sie jeweils ähnliche Dokumente anzeigen lassen

Ähnlichkeit auf der Basis der in dem Dokument enthaltenen Terme oder eingeschränkt auf die enthaltenen Personen und Ortsnamen



Ähnliche Dokumente basierend auf den Feldern Volltext

### **Topic Models**



# Topic Modeling: Geeignete Einführungen & Kritik

Blei, D. M. (2012). Topic Modeling and Digital Humanities. *Journal of Digital Humanities*, 2(1). Abgerufen August 21, 2014, von <a href="http://journalofdigitalhumanities.org/2-1/topic-modeling-and-digital-humanities-by-david-m-blei/">http://journalofdigitalhumanities.org/2-1/topic-modeling-and-digital-humanities-by-david-m-blei/</a>

Weingart, S. (2012, Juli 25). Topic Modeling for Humanists: A Guided Tour. *the scottbot irregular*. Abgerufen September 13, 2014, von <a href="http://www.scottbot.net/HIAL/?p=19113">http://www.scottbot.net/HIAL/?p=19113</a>

tedunderwood. (2012). Topic modeling made just simple enough. *The Stone and the Shell*. Abgerufen August 21, 2014, von <a href="http://tedunderwood.com/2012/04/07/topic-modeling-made-just-simple-enough/">http://tedunderwood.com/2012/04/07/topic-modeling-made-just-simple-enough/</a>

Schmidt, B. M. (2013). Words Alone: Dismantling Topic Models in the Humanities. *Journal of Digital Humanities*. Abgerufen April 7, 2016, von <a href="http://journalofdigitalhumanities.org/2-1/words-alone-by-benjamin-m-schmidt/">http://journalofdigitalhumanities.org/2-1/words-alone-by-benjamin-m-schmidt/</a>

# **Topic-Modeling im Projekt**

#### Vorverarbeitung

- OCR-Nachkorrektur
- Lemmatisierung -> Reduktion auf Grundformen
- Nur großgeschriebene Lemmata -> Substantive

### 3 Topicmodelle verfügbar

- 50 Topics
- 100 Topics
- 200 Topics

### **TM 50 Topics**

- 1. [Gott Mensch Herr Herz Leben Wort Welt Himmel Tag Hand]
- 2. [Reich Zeit Staat Volk Deutschland Jahrhundert Land Macht deutsch Geschichte]
- 13. [Athen Stadt Athener Sparta Spartaner Griechenland Krieg Perser Flotte König]
- 36. [Handel Industrie Land Ackerbau Fabrik Stadt Deutschland Mill Viehzucht Gewerbe]

#### **TM 200 Topics**

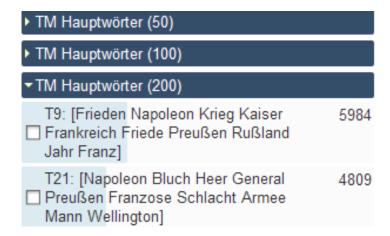
- 1: [Kind Lehrer Schüler Unterricht Schule Frage Stoff Aufgabe Zeit Geschichte]
- 2. [Staat Zeit Volk Deutschland Leben Reich Jahrhundert Macht Entwicklung Gebiet]
- 20. [Preußen Bund Staat König Regierung Deutschland Verfassung Frankfurt Reichstag Bundestag]
- 62. [Papst Kaiser lii Vii Gregor Heinrich Rom Friedrich Italien Jahr]

# **Filtern mit Topics**

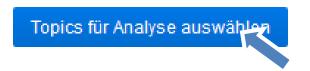
Topic-Modelle auch als Filter verfügbar

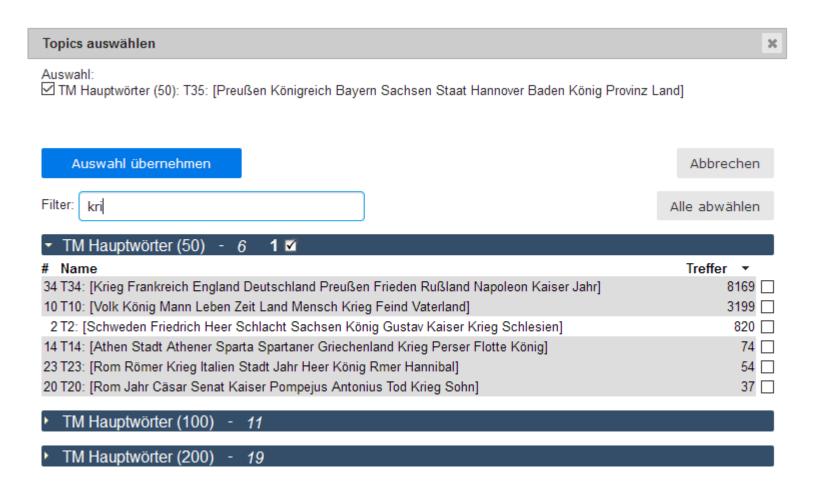
Jeder Seite werden dafür die wichtigsten Topics zugeordnet

Filtern auf ein Topic und gleichzeitige Analyse dieses Topics nicht sinnvoll!



# Topics auswählen für Analyse





# Sortiert nach Häufigkeit in aktuellen Treffern

#### Filtermöglichkeit nach Topic-Term

# Weitere Möglichkeit: Suchterm mit Topic ersetzen

- 1. Suchterme eingeben
- Topics werden nach Häufigkeit zu Suchterm sortiert angezeigt
- Geeignete Topics für Analyse auswählen oder danach filtern
- 4. Suchterm wieder abwählen (!)

# Analyse mit Topics im Diagramm



Mittlere Topic-Intensität im jeweiligen Zeitraum

Mehrere Topics oder Untergruppen in einer Kategorie ein Topic

# Alle Topics über Gruppen vergleichen z.B. wichtigste Topics zu "napoleon" nach Jahrzehnt

Vollständiges Topic Model (am Besten in Zeilen)

Häufigkeiten für TM Hauptwörter (200) im Vergleich über Erscheinungsjahr n. Jahrzehnten

Z.B. häufigstes Topic in verschiedenen Zeiträumen.

**Ausreißer-Topics** 

Erscheinungsjahr Gesamt 1870 - 1879 1880 - 1889 1860 - 1869 # \$ TM Hauptwörter (200) **+/**-♦ Anzahl 

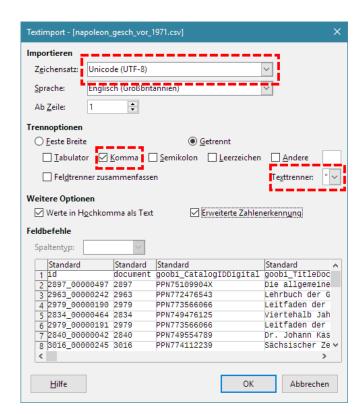
♦ Anteil 

♦ Anzahl 

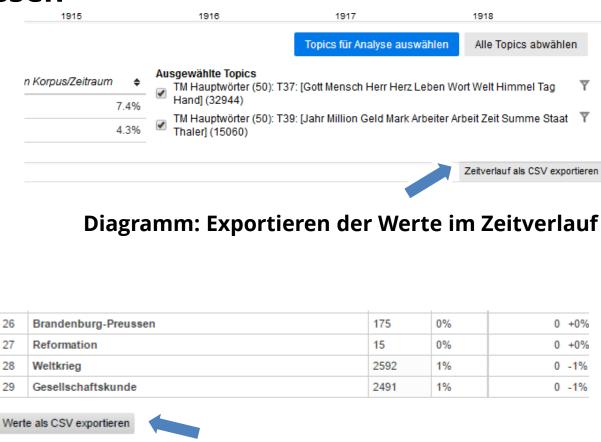
+/- 

♦ Anzahl Anzahl 1. T9: [Frieden Napoleon Krieg..: +9% 1. T9: [Frieden Napoleon Krieg..: +5% 2. T182: [Krieg Jahr Zeit Land..: +5% 2. T73: [König Paris Parlament..: +3% Top-3-Aufsteiger (nur \*\*): 3. T73: [König Paris Parlament..: +4% 3. T197: Italien Mailand Stadt Rom ..: +3% 1. T54: [Staat Zeit Volk Deutschland..: -5% 1. T54: [Staat Zeit Volk Deutschland..: -3% 2. T71: [Deutschland Krieg Preußen..: -5% 2. T183: [Kind Lehrer Schüler..: -3% Top-3-Absteiger (nur \*\*): 3. T35: [König Bismarck Wilhelm..: -5% 3. T65: [König Herr Soldat Offizier..: -1% 25249 3 0% 12% 4058 16% Seitenzahl pro Erscheinungsjahr: 3279 T9: [Frieden Napoleon Krieg Kaiser Frankreich Friede 7685 30% 3 +70% 1292 +9%\*\* 1434 +5%\*\* Preußen Rußland Jahr Franz] T21: [Napoleon Bluch Heer General Preußen Franzose 6691 26% 1 +7% 893 +1% 1119 +1% Schlacht Armee Mann Wellington] T71: [Deutschland Krieg Preußen Volk Napoleon Frankreich 20% 0 -21% 525 -5%\*\* 778 -2% Macht Frieden Europa Land] T35: [König Bismarck Wilhelm Kaiser General Minister Stein 14% 2 +52% 529 -1% 324 -5%\*\* Berlin Graf Moltkel T156: [Schlacht Sieg Feind Heer König Mann Kampf Tag 3517 13% 0 -14% 506 +2% 546 +0% Tapferkeit Franzosel 3164 T176: [Frankreich England Rußland Deutschland Preußen 12% 0 -13% 506 +3%\* 554 +1% Krieg Italien Spanien Schweden Holland] T54: [Staat Zeit Volk Deutschland Leben Reich Jahrhundert 3070 12% 0 -12% 219 -5%\*\* 366 -3%\*\* Macht Entwicklung Gebiet] T59: [Tod Leben Volk Herz Freund Mann Wort König Tag 2903 11% 0 -11% 344 -1% 410 -1% Feind] T81: [Herz Himmel Gott Welt Lied Leben Auge Erde Land 2718 10% 0 -11% 355 +0% 382 -1% Nacht] 10 T67: [Preußen Bund Staat König Regierung Deutschland 2645 10% 2 +56% 371 +1% 412 +0% Verfassung Frankfurt Reichstag Bundestag] T140: [Stadt Franzose Feind Festung Truppe Tag Mann Paris 2602 10% 0 -10% 395 +2% 454 +1% Belagerung Angriff]

# **Exportieren von Analyseergebnissen**



Importieren des CSV-Formats (comma-separated-values)
Beispiel LibreOffice Calc.



**Vergleichsmatrix: Exportieren der Tabelle (ohne Vergleich +/-)** 

Achtung: Dateiname und Dateiendung müssen selbst vergeben werden (\*.csv)

# **Exportieren von Dokumenten**



#### Formular:

Export beliebiger Anzahl der Treffer (nach aktueller Sortierung, öffnet in neuem Fenster

#### Link: Normalisierte Texte aller aktuellen Treffer

Direkt speichern, Alle Treffer, Text normalisiert wie für Topic Modeling verwendet

## Weitere Hinweise in PDF: Export von Treffern als CSV zur Analyse in externen Werkzeugen

mit Beispielanalyse in ConText

LibreOffice-Macro, mit dem die CSV-Dateien in einzelne Textdateien geteilt werden können

# **Dokumentation von Ergebnissen**

Aktuelle Seite als Lesezeichen speichern – Titel anpassen

**Screenshots (Alt-Druck)** 

#### Daten aus Tabellen kopieren

Datentabelle (Legende) in Diagramm

Vergleich Kategorie x Kategorie: Alles markieren (Strg-A) und kopieren

#### **Hochauflösende Diagramme**

Als SVG speichern: Crowbar2 (!) <a href="http://nytimes.github.io/svg-crowbar/">http://nytimes.github.io/svg-crowbar/</a>

Export der Textseiten im zweiten Teil des Tutorials

# Institutionen & Mitarbeiter

# Geisteswissenschaften

# GEORG ECKERT INSTITUT

Leibniz-Institut für internationale Schulbuchforschung

Prof. Dr. Simone Lässig Prof. Dr. Ernesto William De Luca Andreas Weiß Maik Fiedler

Robert Strötgen (assoziiert)

# Computerlinguistik/Informatik





Prof. Dr. Irina Gurevych Carsten Schnober

Dr. Richard Eckart de Castilho (assoziiert)

# Informationswissenschaft

Prof. Dr. Christa Womser-Hacker Prof. Dr. Thomas Mandl Dr. Ben Heuwing

